

**Implementasi Machine Learning untuk Klasifikasi Tingkat Risiko
Kelulusan Mahasiswa Menggunakan Algoritma Decision Tree C4.5 pada
College Student Management Dataset**



Dosen Pengampu :

INDAH WERDININGSIH S.Si., M.Kom.

DISUSUN OLEH:

Kelompok 9

Andino Ferdiansah	434231065
Sayu Damar Yunan	434231079
Muhammad Catra Hanif Azmi	434231104

PROGRAM STUDI D-IV TEKNIK INFORMATIKA

FAKULTAS VOKASI

UNIVERSITAS AIRLANGGA

SURABAYA

2026

DAFTAR ISI

BAB I PENDAHULUAN.....	3
1.1 Latar Belakang.....	3
1.2. Tujuan.....	3
1.3 Penelitian Terdahulu.....	4
BAB II DATA.....	5
2.1 Deskripsi Dataset.....	5
2.2 Variabel Yang Digunakan.....	5
2.3 Visualisasi variabel dataset.....	7
BAB III METODOLOGI.....	8
3.1 Flowchart Metodologi.....	8
3.2 Tahapan Penelitian.....	8
3.3 Parameter Eksperimen.....	9
BAB IV HASIL.....	10
4.1 Hasil Data Selection.....	10
4.2 Hasil Preprocessing.....	10
4.3 Hasil Transformation.....	11
4.4 Hasil Data Mining.....	11
4.5 Hasil Evaluation.....	13

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perguruan tinggi menyimpan banyak data akademik dan data aktivitas belajar, misalnya nilai, beban mata kuliah, kehadiran, dan aktivitas pada Learning Management System. Data ini dapat dipakai untuk mendukung keputusan berbasis bukti, termasuk mendeteksi mahasiswa yang berisiko mengalami masalah akademik lebih awal, sehingga tindak lanjut dapat dilakukan lebih cepat.

Laporan praktikum ini membahas implementasi klasifikasi untuk memprediksi tingkat_risiko mahasiswa menggunakan College Student Management Dataset. Dataset tersebut memuat catatan mahasiswa yang mencakup performa akademik, metrik keterlibatan pada LMS, dan label tingkat_risiko. Metode yang digunakan adalah algoritma pohon keputusan C4.5 karena mampu menangani atribut kategorikal maupun numerik, serta menghasilkan aturan keputusan yang mudah diinterpretasikan.

Pada implementasi terbaru, proses analisis tidak hanya mencakup pembersihan data, transformasi, pemodelan, dan evaluasi, tetapi juga repeated evaluation pada beberapa pembagian data untuk menilai kestabilan kinerja model serta analisis konsistensi label target terhadap aturan keputusan yang terbentuk.

1.2. Tujuan

Berdasarkan latar belakang di atas, didapat tujuan sebagai berikut:

1. Menyiapkan dan membersihkan data sehingga fitur dan target siap dipakai untuk proses pelatihan model.
2. Mengimplementasikan algoritma C4.5 untuk melakukan klasifikasi tingkat_risiko mahasiswa.
3. Mengukur kestabilan kinerja model melalui repeated evaluation pada beberapa pembagian data.
4. Menghasilkan aturan keputusan dari pohon keputusan sebagai bentuk interpretasi model.
5. Menganalisis konsistensi label target terhadap aturan keputusan yang terbentuk.

1.3 Penelitian Terdahulu

No	Author, Tahun	Judul Penelitian	Tujuan	Metode	Data	Hasil
1	Moh. Roghib, Nining Rahaningsih, dan Raditya Danar Dana, 2024	Penerapan Algoritma C4.5 untuk Seleksi Penjurusan Siswa Baru pada Sekolah Menengah Kejuruan (Studi Kasus: SMK Plus Al-Hilal Arjawinangun)	Mengategorikan jurusan siswa baru agar proses penjurusan lebih tepat dan lebih cepat	KDD dan klasifikasi Decision Tree C4.5 dengan evaluasi confusion matrix	204 record, 6 atribut utama: nama, jenis kelamin, nilai, minat siswa, rekomendasi BK, dan jurusan	Akurasi 98,02%, presisi 98,73%, dan recall 98,73%

Tabel 1. Jurnal Penelitian Terdahulu

BAB II

DATA

2.1 Deskripsi Dataset

Dataset yang digunakan pada proyek ini adalah College Student Management Dataset yang diperoleh dari Kaggle. Dataset terdiri atas 1.545 baris dan 15 kolom. Variabel target yang diprediksi adalah `tingkat_risiko`, sedangkan variabel lainnya merepresentasikan identitas, karakteristik mahasiswa, performa akademik, serta aktivitas belajar berbasis LMS.

Secara komposisi, kelas target terdiri atas 805 data untuk kelas Tinggi (52,10%), 456 data untuk kelas Sedang (29,51%), dan 284 data untuk kelas Rendah (18,38%). Hasil penelusuran awal juga menunjukkan bahwa dataset tidak memiliki nilai kosong maupun baris duplikat, sehingga struktur datanya relatif siap untuk diproses lebih lanjut melalui tahapan KDD.

2.2 Variabel Yang Digunakan

Setiap variabel pada dataset diidentifikasi berdasarkan tipe data aslinya, lalu dikelompokkan menjadi data numerik atau kategorikal. Untuk variabel kategorikal dihitung nilai modus, sedangkan untuk variabel numerik dihitung mean dan median.

Variabel	Tipe Data	Jenis Data	Statistik Ringkas	Keterangan
id_siswa	object	Kategorikal	Seluruh nilai unik, tidak ada modus dominan	Identitas unik mahasiswa
usia	int64	Numerik	Mean = 21,48; Median = 22,00	Usia mahasiswa
jenis_kelamin	object	Kategorikal	Modus = Laki-laki (531 data)	Jenis kelamin mahasiswa
jurusan	object	Kategorikal	Modus = Seni (404 data)	Program studi atau bidang studi


ipk	float64	Numerik	Mean = 3,01; Median = 3,03	Indeks Prestasi Kumulatif
beban_mata_kuliah	int64	Numerik	Mean = 4,49; Median = 5,00	Jumlah mata kuliah yang diambil
rata_rata_nilai_mata_kuliah	float64	Numerik	Mean = 79,91; Median = 79,60	Rata-rata nilai mata kuliah
tingkat_kehadiran	float64	Numerik	Mean = 0,79; Median = 0,79	Persentase kehadiran mahasiswa
status_studi	object	Kategorikal	Modus = Aktif (540 data)	Status studi mahasiswa
login_lms_bulan_lalu	int64	Numerik	Mean = 19,34; Median = 19,00	Jumlah login LMS dalam 1 bulan terakhir
rata_rata_durasi_sesi_menit	int64	Numerik	Mean = 49,37; Median = 49,00	Rata-rata durasi sesi belajar pada LMS
tingkat_pengumpulan_tugas	float64	Numerik	Mean = 0,75; Median = 0,76	Persentase pengumpulan tugas
jumlah_partisipasi_forum	int64	Numerik	Mean = 9,64; Median = 10,00	Jumlah partisipasi forum diskusi
tingkat_penyelesaian_video	float64	Numerik	Mean = 0,75; Median = 0,75	Persentase penyelesaian video pembelajaran
tingkat_risiko	object	Kategorikal	Modus = Tinggi (805 data)	Label tingkat risiko kelulusan mahasiswa

Tabel 2. Variabel Dataset

Dari hasil identifikasi tersebut, dataset terdiri atas 10 variabel numerik dan 5 variabel kategorikal jika kolom identitas tetap dihitung, atau 10 variabel numerik dan 4 variabel kategorikal sebelum id_siswa dikeluarkan dari proses pemodelan.

2.3 Visualisasi variabel dataset

Visualisasi data pada tahap ini difokuskan pada variabel numerik melalui histogram. Histogram digunakan untuk merangkum distribusi data univariat secara grafis, serta membantu menunjukkan pusat data, penyebaran, kemencengan, kemungkinan outlier, dan pola distribusi secara umum. Secara teknis, histogram dibentuk dengan membagi rentang data ke dalam beberapa interval, kemudian menghitung frekuensi observasi pada setiap interval tersebut.




Gambar 1. Histogram variabel numerik dataset

Berdasarkan histogram variabel numerik yang dihasilkan, terlihat bahwa usia tersebar pada rentang 18–25 tahun, IPK berada pada rentang 2,00–4,00, dan variabel keterlibatan belajar seperti tingkat_kehadiran, tingkat_pengumpulan_tugas, serta tingkat_penyelesaian_video cenderung lebih banyak muncul pada rentang menengah hingga tinggi. Temuan ini menunjukkan bahwa dataset memuat variasi perilaku akademik dan aktivitas belajar yang cukup beragam untuk mendukung proses klasifikasi.

BAB III METODOLOGI

3.1 Flowchart Metodologi

Metodologi penelitian mengikuti kerangka KDD yang diadaptasi dari paper rujukan. Pada paper tersebut, alur penelitian disusun melalui lima tahapan utama, yaitu data selection, preprocessing, transformation, data mining, dan evaluation. Struktur ini kemudian diterapkan pada proyek klasifikasi tingkat risiko kelulusan mahasiswa dengan menyesuaikan konteks variabel dan bentuk evaluasinya.



Gambar 2. Flowchart metodologi penelitian

3.2 Tahapan Penelitian

1. Data Selection

Tahap data selection dilakukan dengan memilih kolom-kolom yang relevan untuk prediksi tingkat risiko kelulusan. Kolom `id_siswa` tidak digunakan sebagai fitur karena hanya berfungsi sebagai identitas. Dengan demikian, fitur yang dipertahankan mencakup data demografis, performa akademik, dan aktivitas belajar mahasiswa.

2. Preprocessing

Tahap preprocessing dilakukan dengan menyalin data, merapikan nama kolom, menghapus baris duplikat, menghapus baris yang label targetnya kosong, dan memeriksa kemungkinan konversi tipe data. Pada implementasi, fitur bertipe object akan dicoba dikonversi ke numerik jika sebagian besar nilainya dapat diparse sebagai angka. Untuk kondisi nilai kosong, data numerik akan diimputasi menggunakan median, sedangkan data kategorikal diisi dengan label `Unknown`.

3. Transformation

Tahap transformation dilakukan dengan mengidentifikasi tipe setiap fitur sebagai numerik atau kategorikal. Hasil identifikasi ini menjadi dasar bagi algoritma C4.5 untuk menentukan mekanisme pemisahan node. Fitur numerik dipisahkan menggunakan nilai ambang, sedangkan fitur kategorikal dipisahkan berdasarkan kategori yang tersedia.

4. Data Mining

Tahap data mining dilakukan dengan membangun model klasifikasi menggunakan implementasi C4.5 pada penelitian ini. Secara konsep, decision tree membentuk pohon secara rekursif dengan memilih atribut pemisah yang paling baik, sedangkan C4.5 merupakan pengembangan dari ID3 yang dapat menggunakan gain ratio untuk mengevaluasi split. Decision tree juga dikenal mudah diinterpretasikan karena keputusan model dapat dibaca sebagai aturan if-then. Pada implementasi ini, setelah pohon terbentuk, model menjalankan pruning sederhana menggunakan data validasi internal untuk mengurangi kompleksitas yang tidak diperlukan.

5. Evaluation

Tahap evaluation dilakukan melalui repeated stratified evaluation sebanyak 30 run untuk mengamati kestabilan performa model pada beberapa pembagian data. Evaluasi mengukur accuracy, precision macro, recall macro, dan F1-score macro. Selain itu, laporan juga memanfaatkan confusion matrix representatif, distribusi kelas target, dan visualisasi sebaran IPK serta tingkat kehadiran untuk mendukung interpretasi hasil.

3.3 Parameter Eksperimen

Parameter yang digunakan pada implementasi penelitian diringkas sebagai berikut:

Parameter	Nilai
Ukuran data uji	20% dari keseluruhan data
Ukuran validasi internal	25% dari data latih
max_depth	12
min_samples_split	10
min_gain_ratio	0,000001
Jumlah repeated evaluation	30 run
Seed awal	42

Tabel 3. Parameter eksperimen pada penelitian

BAB IV

HASIL


4.1 Hasil Data Selection

Pada tahap data selection, kolom `id_siswa` dikeluarkan dari himpunan fitur karena tidak memiliki peran prediktif. Setelah seleksi, dataset yang digunakan untuk pemodelan terdiri atas 14 kolom, yaitu 13 fitur prediktor dan 1 target. Target yang dipakai adalah `tingkat_risiko` dengan tiga kelas, yakni Tinggi, Sedang, dan Rendah.

```
print("\n--- 2. Seleksi Data (Memilih Fitur dan Target) ---")
drop_cols = ["id_siswa"]
df = clean_and_prepare(df_raw, target_col=args.target, drop_cols=drop_cols)

print(f"Kolom setelah selection: {list(df.columns)}")
print("Distribusi target:")
print(df[args.target].value_counts())
```

Distribusi kelas menunjukkan bahwa kelas Tinggi merupakan kelas yang paling dominan dengan 805 data, diikuti kelas Sedang sebanyak 456 data, dan kelas Rendah sebanyak 284 data. Komposisi ini menunjukkan bahwa distribusi kelas tidak sepenuhnya seimbang, sehingga penggunaan metrik macro average menjadi penting pada tahap evaluasi. Di bawah ini adalah grafik hasil tahap data selection:



Gambar 3. Distribusi Kelas Tingkat Risiko Kelulusan Mahasiswa

4.2 Hasil Preprocessing

Tahap preprocessing menghasilkan data yang telah rapi dan siap dianalisis. Nama kolom telah diseragamkan, data target telah dibersihkan dari spasi berlebih, dan skema penanganan missing value telah disiapkan pada pipeline. Pada dataset yang digunakan, tidak ditemukan nilai kosong maupun data duplikat, sehingga proses preprocessing terutama berfungsi sebagai langkah validasi dan standarisasi sebelum data diproses lebih lanjut.

```
def clean_and_prepare(df: pd.DataFrame, target_col: str, drop_cols: list):
    df = df.copy()
    df.columns = [c.strip() for c in df.columns]
    df = df.drop_duplicates()

    if target_col not in df.columns:
        raise ValueError(f"Kolom target '{target_col}' tidak ditemukan. Kolom yang ada: {list(df.columns)}")

    for c in drop_cols:
        if c in df.columns:
            df = df.drop(columns=[c])

    df = df.dropna(subset=[target_col])

    for col in df.columns:
        if col == target_col:
            continue
        if df[col].dtype == "object":
            s = df[col].astype(str).str.strip().str.replace(", ", "", regex=False)
            num = pd.to_numeric(s, errors="coerce")
            if num.notna().mean() >= 0.95:
                df[col] = num
            else:
                df[col] = df[col].astype(str).str.strip()

    for col in df.columns:
        if col == target_col:
            continue
        if pd.api.types.is_numeric_dtype(df[col]):
            df[col] = df[col].fillna(df[col].median())
        else:
            df[col] = df[col].fillna("Unknown").astype(str)

    df[target_col] = df[target_col].astype(str).str.strip()
    return df
```

```
--- 3. Pemahaman Data (Info & Statistik Singkat) ---
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1545 entries, 0 to 1544
Data columns (total 14 columns):
#   Column                                Non-Null Count  Dtype
---  ---                                -
0   usia                                  1545 non-null   int64
1   jenis_kelamin                        1545 non-null   object
2   jurusan                             1545 non-null   object
3   ipk                                  1545 non-null   float64
4   beban_mata_kuliah                    1545 non-null   int64
5   rata_rata_nilai_mata_kuliah          1545 non-null   float64
6   tingkat_kehadiran                    1545 non-null   float64
7   status_studi                         1545 non-null   object
8   login_lms_bulan_lalu                 1545 non-null   int64
9   rata_rata_durasi_sesi_menit           1545 non-null   int64
10  tingkat_pengumpulan_tugas            1545 non-null   float64
11  jumlah_partisipasi_forum             1545 non-null   int64
12  tingkat_penyelesaian_video           1545 non-null   float64
13  tingkat_risiko                       1545 non-null   object
dtypes: float64(5), int64(5), object(4)
memory usage: 169.1+ KB
```

Keberadaan tahapan preprocessing tetap penting karena menjamin bahwa aplikasi dapat berjalan secara konsisten apabila di kemudian hari dataset diganti atau diperbarui. Dengan demikian, model tidak hanya sesuai untuk data saat ini, tetapi juga lebih siap menghadapi variasi kualitas data pada eksperimen berikutnya.

4.3 Hasil Transformation

```
print("\n--- 4. Pemisahan Data (Latih/Uji) ---")
X = df.drop(columns=[args.target])
y = df[args.target]

X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=args.test_size,
    random_state=42,
    stratify=y
)
print(f"Jumlah data latih: {len(X_train)} baris")
print(f"Jumlah data uji : {len(X_test)} baris")

print("\n--- 5. Pemisahan Internal Latih/Validasi (untuk pruning sederhana) ---")
X_tr, X_val, y_tr, y_val = train_test_split(
    X_train, y_train,
    test_size=args.val_size,
    random_state=42,
    stratify=y_train
)
print(f"Train untuk bangun pohon: {len(X_tr)} baris")
print(f"Validation untuk pruning: {len(X_val)} baris")
```

Pada tahap transformation di atas, terlihat bahwa fitur yang digunakan dalam pemodelan terbagi menjadi 10 fitur numerik dan 3 fitur kategorikal setelah id_siswa dikeluarkan. Pembagian ini sesuai dengan identifikasi tipe fitur secara otomatis berdasarkan struktur data setelah proses pembersihan, yakni:

1. **Fitur numerik** meliputi : usia, ipk, beban_mata_kuliah, rata_rata_nilai_mata_kuliah,tingkat_kehadiran,login_lms_bulan_lalu,rata_rata_durasi_sesi_menit,tingkat_pengumpulan_tugas,jumlah_partisipasi_forum,dan tingkat_penyelesaian_video.
2. **fitur kategorikal** meliputi : jenis_kelamin, jurusan, dan status_studi. Hasil transformation ini menentukan cara model C4.5 membangun aturan pemisahan pada setiap node.


4.4 Hasil Data Mining

Pada tahap data mining, model C4.5 dibentuk menggunakan kriteria gain ratio untuk memilih atribut pemisah terbaik. Berdasarkan pohon keputusan representatif yang dihasilkan, keputusan model terutama ditentukan oleh dua atribut utama, yaitu tingkat_kehadiran dan ipk. Hal ini menunjukkan bahwa kedua variabel tersebut menjadi penentu paling kuat dalam memisahkan kelas tingkat risiko kelulusan mahasiswa.

```
print("\n--- 7. Penambangan Data (Pelatihan C4.5) ---")
model = C45Classifier(
    max_depth=args.max_depth,
    min_samples_split=args.min_samples_split,
    min_gain_ratio=args.min_gain_ratio
)
model.fit(X_tr, y_tr, feature_types=feature_types)
```

Aturan keputusan ringkas yang terbentuk dapat dirangkum sebagai berikut. Pertama, jika tingkat_kehadiran kurang dari atau sama dengan 0,745 maka mahasiswa diklasifikasikan ke kelas Tinggi. Kedua, jika tingkat_kehadiran lebih dari 0,745 tetapi ipk kurang dari atau sama dengan 2,495 maka mahasiswa tetap berada pada kelas Tinggi. Ketiga, jika

tingkat_kehadiran lebih dari 0,745, ipk lebih dari 2,495, dan tingkat_kehadiran kurang dari atau sama dengan 0,845 maka mahasiswa diklasifikasikan ke kelas Sedang. Keempat, jika tingkat_kehadiran lebih dari 0,845 tetapi ipk kurang dari atau sama dengan 2,995 maka mahasiswa juga berada pada kelas Sedang. Kelima, jika tingkat_kehadiran lebih dari 0,845 dan ipk lebih dari 2,995 maka mahasiswa diklasifikasikan ke kelas Rendah. Hasil dapat dilihat pada gambar grafik dibawah ini:



Gambar 4. Sebaran IPK dan tingkat kehadiran terhadap tingkat risiko

Sebaran pada Gambar 4 memperlihatkan bahwa pemisahan kelas memang sangat dipengaruhi oleh kombinasi IPK dan tingkat kehadiran. Area dengan kehadiran rendah didominasi kelas Tinggi, area dengan kehadiran menengah serta IPK menengah didominasi kelas Sedang, sedangkan area dengan kehadiran tinggi dan IPK tinggi didominasi kelas Rendah. Pola ini mendukung interpretasi bahwa model yang terbentuk bersifat mudah dijelaskan dan konsisten dengan struktur label pada dataset.

1. Jika tingkat_kehadiran kurang dari atau sama dengan 0,745, maka mahasiswa diklasifikasikan ke kelas Tinggi.
2. Jika tingkat_kehadiran lebih dari 0,745 tetapi ipk kurang dari atau sama dengan 2,495, maka mahasiswa tetap diklasifikasikan ke kelas Tinggi.
3. Jika tingkat_kehadiran lebih dari 0,745, ipk lebih dari 2,495, dan tingkat_kehadiran kurang dari atau sama dengan 0,845, maka mahasiswa diklasifikasikan ke kelas Sedang.

4. Jika tingkat_kehadiran lebih dari 0,845 tetapi ipk kurang dari atau sama dengan 2,995, maka mahasiswa juga diklasifikasikan ke kelas Sedang.
5. Jika tingkat_kehadiran lebih dari 0,845 dan ipk lebih dari 2,995, maka mahasiswa diklasifikasikan ke kelas Rendah.

Sebaran data pada grafik IPK dan tingkat kehadiran memperlihatkan bahwa pemisahan kelas memang sangat dipengaruhi oleh kombinasi kedua variabel tersebut. Area dengan kehadiran rendah didominasi kelas Tinggi, area dengan kehadiran menengah serta IPK menengah didominasi kelas Sedang, sedangkan area dengan kehadiran tinggi dan IPK tinggi didominasi kelas Rendah. Pola ini mendukung interpretasi bahwa model yang terbentuk bersifat mudah dijelaskan dan konsisten dengan struktur label pada dataset.

4.5 Hasil Evaluation

```
print("\n--- 8. Evaluasi (Pruning + Matriks Kebingungan) ---")
model.prune(X_val, y_val)
y_pred = model.predict(X_test)

acc = accuracy_score(y_test, y_pred)
pr, rc, f1, _ = precision_recall_fscore_support(y_test, y_pred, average="macro", zero_division=0)

print(f"Akurasi : {acc:.4f}")
print(f"Presisi : {pr:.4f} (macro)")
print(f"Recall : {rc:.4f} (macro)")
print(f"F1-score: {f1:.4f} (macro)")

labels = sorted(y.unique().tolist())
cm = confusion_matrix(y_test, y_pred, labels=labels)
print("\nMatriks Kebingungan (baris=aktual, kolom=prediksi):")
cm_df = pd.DataFrame(cm, index=[f"aktual_{l}" for l in labels], columns=[f"prediksi_{l}" for l in labels])
print(cm_df)
```


Pada tahap evaluation mengikuti pola pada paper rujukan, tetapi pelaksanaannya disesuaikan dengan implementasi. Evaluasi dilakukan melalui repeated stratified evaluation sebanyak 30 run untuk mengamati kestabilan performa model pada beberapa pembagian data. Ringkasan hasil repeated evaluation disajikan pada tabel berikut:

Metrik	Mean	Minimum	Maksimum
Accuracy	0,999245	0,990291	1,000000
Precision macro	0,999243	0,993902	1,000000
Recall macro	0,999179	0,989011	1,000000

F1-score macro	0,999204	0,991336	1,000000
----------------	----------	----------	----------

Tabel 4. Hasil Evaluasi Penelitian.

Berdasarkan repeated evaluation tersebut, model menunjukkan performa yang sangat tinggi dan stabil. Proporsi run yang menghasilkan metrik sempurna mencapai 25 dari 30 run (83,33%). Temuan ini menandakan bahwa pola kelas pada dataset sangat kuat dan dapat dipelajari dengan baik oleh model C4.5.



Gambar 5. Confusion Matrix Representatif Tingkat Risiko Kelulusan Mahasiswa

Confusion matrix representatif yang ditampilkan pada hasil akhir menunjukkan total 309 data uji, dengan komposisi berikut:

- aktual Rendah diprediksi Rendah sebanyak 57 data,
- aktual Sedang diprediksi Rendah sebanyak 2 data,
- aktual Sedang diprediksi Sedang sebanyak 89 data,
- aktual Tinggi diprediksi Tinggi sebanyak 161 data.

Dengan demikian, total 307 dari 309 data berhasil diprediksi dengan benar sehingga akurasi representatif mencapai 99,35%. Perhitungan dari confusion matrix tersebut menghasilkan precision macro 98,87%, recall macro 99,27%, dan F1-score macro 99,05%. Nilai-nilai ini konsisten dengan isi gambar output yang Anda lampirkan.

Kesalahan klasifikasi hanya terjadi pada dua data kelas Sedang yang diprediksi sebagai Rendah, sedangkan kelas Tinggi seluruhnya diprediksi dengan benar. Hasil evaluasi tersebut menunjukkan bahwa model C4.5 sangat efektif untuk mengenali struktur kelas pada dataset ini. Meskipun demikian, tingginya performa perlu ditafsirkan secara hati-hati karena aturan kelas pada data tampak sangat jelas dan dominan ditentukan oleh dua variabel utama. Dengan kata lain, keberhasilan model bukan hanya disebabkan oleh kemampuan algoritma, tetapi juga karena pola label dalam dataset memang relatif mudah dipisahkan.

REFERENSI

M. Roghib, N. Rahaningsih, dan R. D. Dana, "Penerapan Algoritma C4.5 untuk Seleksi Penjurusan Siswa Baru pada Sekolah Menengah Kejuruan (Studi Kasus: SMK Plus Al-Hilal Arjawinangun)," *JATI (Jurnal Mahasiswa Teknik Informatika)*, vol. 8, no. 1, hlm. 861–866, 2024, doi: 10.36040/jati.v8i1.8436.

<https://pdfs.semanticscholar.org/7ee0/e7b2fc12fcb550f83dd49cc193fa064c955c.pdf>

Ziya, "College Student Management Dataset," Kaggle. Dataset ini berisi catatan mahasiswa anonim yang menggabungkan performa akademik, metrik keterlibatan LMS, dan label risiko untuk kebutuhan penelitian pengelolaan pendidikan tinggi berbasis AI.

<https://www.kaggle.com/datasets/ziya07/college-student-management-dataset>